

PRÁCTICAS PROFESIONALIZANTES II

2° AÑO 2° CUATRIMESTRE

Clase N° 3: ENTORNOS DE PROCESAMIENTO DISTRIBUIDO Y EN TIEMPO

REAL

Contenido:

En la clase de hoy trabajaremos los siguientes temas:

[Introducción a Big Data](#)

[Procesamiento batch vs. en tiempo real](#)

[Arquitecturas distribuidas](#)

[Herramientas: Hadoop y Apache Spark](#)

1. Presentación:

Bienvenidos a la *clase N° 3* del bloque *Prácticas Profesionalizantes II*.

En la clase pasada analizamos diferentes herramientas de almacenamiento NoSQL como Neo4j y Elasticsearch, y discutimos los criterios técnicos para seleccionar tecnologías según el tipo de datos.

En esta clase desarrollaremos el tema “Entornos de procesamiento distribuido y en tiempo real”, y abordaremos conceptos clave como Big Data, procesamiento batch vs. en tiempo real, y arquitecturas distribuidas, explorando herramientas como Hadoop y Apache Spark.

Este conocimiento es fundamental porque permite comprender cómo se procesan los grandes volúmenes de datos generados en sistemas reales, y cómo diseñar soluciones que respondan en tiempo y forma a las necesidades de los usuarios. Además, nos prepara para integrar procesamiento y almacenamiento en proyectos con enfoque productivo.

Te invitamos ahora a leer el artículo de Kreps (2011), *The Log: What Every Software Engineer Should Know About Real-Time Data's Unifying Abstraction*, disponible en los materiales de la clase.

Mientras lo hacés, te pedimos que registres en una tabla las principales diferencias entre el procesamiento batch y el procesamiento en tiempo real:

- ¿Qué ventajas ofrece cada uno?
- ¿En qué contextos es más adecuado uno u otro?
- ¿Qué desafíos técnicos plantea cada enfoque?

Al finalizar la lectura, reflexioná sobre cómo estos conceptos se conectan con lo que ya vimos sobre el almacenamiento de datos, y cómo influyen en el diseño de una arquitectura de procesamiento distribuida moderna.

2. Desarrollo

Los conceptos que estudiaremos en esta clase se relacionan directamente con lo que vimos en la *clase N° 2*, donde abordamos distintas herramientas para el almacenamiento de datos y analizamos cómo la estructura, el volumen y la naturaleza de los datos influyen en la elección tecnológica. También se vinculan con aprendizajes previos de los bloques de *Bases de Datos*, *Procesamiento de Datos* y *Minería de Datos*, donde trabajamos el análisis de información y los fundamentos del tratamiento de datos en distintos contextos.

En esta oportunidad, nos centraremos en el *procesamiento de datos a gran escala* mediante entornos distribuidos y en tiempo real. Si no recordás con claridad los contenidos de la clase anterior o necesitás

refrescar algunos conceptos, te recomendamos que revises el material de la Clase N° 2 en el campus y consultes los foros donde se discutieron las decisiones tecnológicas vinculadas al almacenamiento.

Para comprender mejor este tema, debemos apropiarnos de una nueva serie de herramientas teóricas y prácticas. Por eso, te invitamos a recorrer detenidamente la lectura de la clase, revisar la *bibliografía propuesta* —especialmente los textos de Karau et al. (2015), Lantz (2019) y Kreps (2011)— y realizar las *actividades integradoras* que te permitirán consolidar los conceptos clave.

Si te surgen dudas, recordá que siempre podés asistir a los *encuentros sincrónicos*, donde retomamos los temas más complejos, respondemos consultas y compartimos experiencias entre pares.

Introducción a Big Data

En la actualidad, los sistemas digitales generan un volumen de datos sin precedentes. Desde sensores industriales hasta redes sociales, pasando por registros financieros, historiales médicos o transacciones de comercio electrónico, el flujo de información es constante, creciente y muchas veces impredecible. Este escenario es lo que ha dado origen al concepto de *Big Data*, un término que no refiere únicamente a la cantidad de datos, sino a una transformación profunda en la forma en que los datos son gestionados, almacenados y procesados.

Según Karau et al. (2015), *Big Data es un paradigma tecnológico que implica trabajar con conjuntos de datos tan grandes, diversos o veloces que superan la capacidad de los sistemas tradicionales*. Estos datos no solo son voluminosos, sino también variables,

PRÁCTICA PROFESIONALIZANTE II

2º 2º Cuatrimestre



complejos, y se producen a alta velocidad. Para describir este fenómeno, suele utilizarse el modelo de las "V" de Big Data: *Volumen, Velocidad, Variedad, Veracidad y Valor*. Cada una de estas dimensiones representa un desafío distinto: desde el almacenamiento físico hasta la interpretación en tiempo real y la extracción de conocimiento útil.

El surgimiento de Big Data no es solo consecuencia del desarrollo tecnológico, sino también de un cambio cultural y económico. Las organizaciones hoy entienden que los datos no son subproductos de su actividad, sino *activos estratégicos que deben ser gestionados de manera eficiente y responsable*. No se trata simplemente de acumular información, sino de diseñar arquitecturas que permitan convertir los datos en decisiones, optimizaciones y oportunidades.

Trabajar con Big Data exige abandonar ciertas prácticas tradicionales. Los enfoques clásicos de bases de datos relacionales o procesamiento centralizado resultan insuficientes para manejar la escala y complejidad actuales. Como lo señala Lantz (2019), "el volumen y la velocidad con que se generan los datos en los sistemas modernos obliga a repensar la arquitectura misma de los procesos". En este sentido, surgen nuevas herramientas, como Hadoop y Spark, que permiten *distribuir el procesamiento entre múltiples nodos*, facilitando una respuesta eficiente incluso frente a volúmenes masivos de datos.

Pero Big Data no implica únicamente escala. También supone *repensar la lógica de trabajo con los datos*: desde cómo se recolectan, hasta cómo se preparan, analizan y visualizan. Exige capacidades técnicas, marcos teóricos y una infraestructura robusta que soporte el crecimiento continuo. Y al mismo tiempo, plantea

nuevos desafíos éticos y sociales sobre la privacidad, la seguridad y el uso de la información.

Introducirse en el mundo de Big Data es mucho más que aprender una nueva tecnología. Es comenzar a comprender cómo se configura el futuro del procesamiento de información en entornos donde la cantidad de datos crece exponencialmente, pero también lo hace su valor estratégico y su capacidad de transformar realidades complejas en decisiones concretas.

Actividad 1

Ahora que te introdujiste en el mundo del Big Data y comprendiste sus dimensiones clave —como volumen, velocidad, variedad y valor—, te proponemos una actividad que te permitirá *explorar cómo este paradigma se expresa en casos reales*, utilizando asistencia de inteligencia artificial.

Tu desafío será seleccionar un caso real en el que se utilicen estrategias de Big Data. Puede tratarse de una empresa, una institución pública, una startup o un proyecto científico. Podés elegir uno de los siguientes ejemplos o buscar otro que te resulte interesante:

- Análisis de comportamiento del consumidor en plataformas de streaming.
- Gestión de datos en tiempo real en servicios de movilidad como Uber o Cabify.
- Uso de sensores en agricultura de precisión.
- Monitoreo epidemiológico con datos abiertos.

PRÁCTICA PROFESIONALIZANTE II

2º 2º Cuatrimestre



Una vez seleccionado el caso, accedé a una herramienta de IA como *ChatGPT*, *Bing Copilot* o *Perplexity AI* y pedile que te ayude a responder las siguientes preguntas:

- ¿Qué tipo de datos procesa este sistema y con qué volumen estimado trabaja?
- ¿Qué herramientas o arquitecturas de Big Data se utilizan (por ejemplo: Hadoop, Spark, bases distribuidas)?
- ¿Cuáles son los beneficios y riesgos del uso de datos a esta escala en ese contexto?

Luego, con la información recolectada y la ayuda del modelo de IA, elaborá un texto breve (200 a 250 palabras) donde expliques el caso elegido, el enfoque tecnológico aplicado y una reflexión personal sobre los desafíos del uso masivo de datos. Podés complementar la actividad incluyendo un esquema visual (opcional) generado con ayuda de alguna herramienta como *Canva*, *Whimsical* o *Diagramas de Google*.

Esta actividad te ayudará a *poner en diálogo los conceptos teóricos con situaciones reales*, incorporar la asistencia inteligente como herramienta de indagación y ejercitar una mirada crítica sobre las tecnologías de procesamiento masivo de datos.

Procesamiento batch vs. en tiempo real

Uno de los aspectos centrales del ecosistema Big Data no solo tiene que ver con cuánto se almacena o qué herramientas se utilizan, sino con *cómo se procesan los datos*. En función del objetivo y del momento en que se requiere actuar sobre la información, existen dos grandes enfoques: *procesamiento por lotes (batch)* y *procesamiento en tiempo real (real-time o streaming)*.

El procesamiento batch es una estrategia clásica que consiste en *acumular datos durante un período de tiempo determinado para luego procesarlos todos juntos en una sola operación*, normalmente programada. Por ejemplo, un sistema que actualiza cada noche los reportes de ventas de todas las sucursales de una cadena comercial está aplicando un modelo batch. Este enfoque es ideal cuando no se requiere inmediatez, y resulta eficiente para operaciones complejas sobre grandes volúmenes de datos históricos. Tecnologías como *Apache Hadoop*, especialmente su componente *MapReduce*, han sido pioneras en este tipo de procesamiento, permitiendo distribuir las tareas en múltiples nodos y gestionar grandes cargas de trabajo con relativa estabilidad y escalabilidad (Shvachko et al., 2010).

En cambio, el procesamiento en tiempo real parte de una necesidad distinta: *actuar sobre los datos tan pronto como son generados*, casi sin latencia. Este modelo es cada vez más común en contextos donde las decisiones deben tomarse al instante, como el monitoreo de fraudes bancarios, las alertas de seguridad, la geolocalización de flotas o el análisis de redes sociales en vivo. Herramientas como *Apache Spark Streaming* permiten este tipo de procesamiento, combinando la potencia del procesamiento distribuido con flujos de datos continuos (Karau et al., 2015).

Ahora bien, la elección entre batch y real-time no es una dicotomía cerrada. Como lo expone Kreps (2011), la verdadera clave está en entender que ambas estrategias pueden coexistir dentro de un sistema bien diseñado. Muchas veces se requiere procesar información en tiempo real para decisiones inmediatas, pero también consolidarla en lotes para análisis posteriores más profundos. Es por eso que arquitecturas modernas como *Lambda Architecture* o *Kappa Architecture* han sido propuestas para combinar lo mejor de ambos

mundos, organizando los flujos de datos de modo que permitan un procesamiento escalable, confiable y flexible.

Desde una perspectiva técnica, la diferencia entre ambos modelos no está solo en la velocidad, sino también en *cómo se gestiona la tolerancia a fallos, la latencia, el costo computacional y la complejidad del sistema*. Por ejemplo, sistemas en tiempo real requieren infraestructuras más robustas, monitoreo constante y mayor capacidad de reacción ante errores. A su vez, el batch permite más control sobre la calidad del dato y mayor eficiencia en procesos que no son sensibles al tiempo.

A medida que avanzamos hacia entornos cada vez más conectados y exigentes, la capacidad de seleccionar, combinar o adaptar estos enfoques según el proyecto será una habilidad clave para los y las profesionales en Ciencia de Datos e Inteligencia Artificial. Entender sus fundamentos y aplicaciones permite tomar decisiones más conscientes al momento de diseñar soluciones informáticas robustas, seguras y alineadas con las necesidades del contexto.

Actividad 2

Luego de leer la sección sobre *procesamiento por lotes y en tiempo real*, te invitamos a aplicar estos conceptos a un escenario concreto. Esta actividad te permitirá identificar las fortalezas y limitaciones de cada enfoque, y ejercitar tu capacidad de análisis en función del contexto.

Imaginá que estás participando en el diseño de un sistema de monitoreo de sensores para una red de agua potable en una ciudad mediana. Los sensores recogen datos como presión, caudal y posibles fugas, y se actualizan cada 30 segundos. Además, la empresa

necesita generar reportes diarios para áreas administrativas y estadísticas mensuales para entes regulatorios.

Con base en esta situación, elaborá un breve texto (150 a 200 palabras) en el que expliques:

- ¿Qué parte del sistema implementarías con un enfoque batch y cuál con un enfoque en tiempo real?
- ¿Qué criterios técnicos y funcionales te ayudaron a tomar esa decisión?
- ¿Qué ventajas creés que aporta combinar ambos modelos en una solución híbrida?

Podés guiarte con las ideas presentadas en los textos de *Karau et al. (2015)*, *Lantz (2019)* y *Kreps (2011)*, pero también es importante que razones desde tu propia comprensión del problema.

Esta actividad te ayudará a fortalecer tu criterio técnico, a reflexionar sobre las decisiones de arquitectura de datos y a prepararte para futuros escenarios donde se integran múltiples formas de procesamiento para responder a necesidades reales.

Arquitecturas distribuidas

A medida que crece el volumen y la complejidad de los datos, también aumenta la necesidad de contar con sistemas capaces de procesarlos de forma eficiente, flexible y escalable. Es en este contexto donde surgen las *arquitecturas distribuidas*, una pieza clave del ecosistema Big Data.

Una arquitectura distribuida se basa en la *coordinación de múltiples nodos (computadoras o servidores) que trabajan de manera conjunta para almacenar, procesar y transmitir datos*. En lugar de

depender de una única máquina potente, se distribuye la carga de trabajo en distintos puntos del sistema, lo que permite escalar horizontalmente —es decir, agregar más nodos— sin rediseñar todo desde cero.

Uno de los modelos más representativos es el de *Apache Hadoop*, que implementa este paradigma mediante dos componentes principales: *HDFS (Hadoop Distributed File System)* y *MapReduce*. HDFS permite almacenar datos de forma redundante y distribuida, lo que garantiza tolerancia a fallos y alta disponibilidad. MapReduce, por su parte, divide los trabajos de procesamiento en dos fases: mapeo (donde se fragmenta la tarea) y reducción (donde se agrupan los resultados). Este enfoque fue fundamental en la historia del procesamiento distribuido y todavía hoy se utiliza en muchos contextos industriales (Shvachko et al., 2010).

Sin embargo, como señalan Karau et al. (2015), Hadoop tiene limitaciones cuando se trata de trabajar con datos en tiempo real o interactivos. Por eso, en los últimos años surgieron herramientas como *Apache Spark*, que también funciona bajo el paradigma distribuido, pero con una arquitectura más moderna y flexible. Spark permite cargar datos en memoria, lo que acelera drásticamente los tiempos de respuesta frente a Hadoop, y ofrece APIs en lenguajes como Python, Scala y Java, integrando procesamiento batch y streaming en una misma plataforma.

El diseño de arquitecturas distribuidas también plantea nuevos desafíos: la sincronización entre nodos, el manejo de errores, la latencia en las comunicaciones, y la consistencia de los datos. Frente a estos dilemas, se han propuesto diversos modelos y patrones de arquitectura, como *Lambda* y *Kappa*, que permiten organizar los flujos

de datos según se requiera almacenamiento histórico, respuesta inmediata o ambas.

Además, herramientas como *Apache Kafka* (para gestión de flujos de datos) y *Apache Storm* (para procesamiento distribuido en tiempo real) amplían el repertorio disponible, facilitando el diseño de soluciones robustas, escalables y adaptables a distintos entornos. Como señala Kreps (2011), el verdadero valor está en pensar la arquitectura de datos como un sistema vivo, capaz de responder al cambio constante en la generación, el uso y la demanda de información.

Comprender las arquitecturas distribuidas no solo es un aspecto técnico, sino también estratégico: implica tomar decisiones conscientes sobre cómo se moverán y transformarán los datos en cada etapa de una solución informática, y cómo esas decisiones impactarán en el rendimiento, la escalabilidad y la sostenibilidad del sistema a largo plazo.

Actividad 3

Ahora que conocés los fundamentos de las arquitecturas distribuidas y exploraste herramientas como Hadoop, Spark y Kafka, te proponemos una actividad que te desafía a *tomar decisiones de diseño informadas* en un escenario realista.

Imaginá que estás colaborando con un equipo que debe desarrollar una solución tecnológica para una plataforma de análisis de datos meteorológicos. Esta plataforma recibe datos en tiempo real desde cientos de estaciones climáticas ubicadas en distintos puntos del país. Además de procesar esos datos para mostrar alertas inmediatas (como tormentas o temperaturas extremas), el sistema debe generar

reportes históricos mensuales y poner a disposición los datos para análisis científicos a gran escala.

Con base en lo que aprendiste en esta clase, elaborá un documento breve (máximo 300 palabras) donde desarrolles las siguientes ideas:

- ¿Qué componentes de una arquitectura distribuida propondrías para este caso?
- ¿Qué herramientas específicas utilizarías para el procesamiento en tiempo real y cuáles para el procesamiento batch?
- ¿Cómo garantizarías la disponibilidad, la escalabilidad y la tolerancia a fallos del sistema?
- ¿Qué criterios técnicos y funcionales respaldan tus decisiones?

Esta actividad busca que pongas en práctica no solo los conocimientos técnicos adquiridos, sino también tu *capacidad de análisis, anticipación de problemas y selección de herramientas adecuadas según las necesidades del contexto*.

Podés apoyarte en los textos de *Karau et al. (2015)* y *Shvachko et al. (2010)* para fundamentar tus elecciones, y si lo considerás útil, incluir un pequeño esquema conceptual o diagrama de alto nivel del sistema que proponés.

Herramientas: Hadoop y Apache Spark

Durante la última década, *Hadoop* y *Apache Spark* se han convertido en dos pilares del procesamiento de datos a gran escala, tanto en entornos académicos como productivos. Estas herramientas no solo permiten trabajar con volúmenes masivos de datos, sino que representan dos enfoques distintos dentro del ecosistema Big Data:

uno más tradicional, centrado en el procesamiento batch, y otro más moderno, que integra procesamiento en memoria y en tiempo real.

Hadoop, desarrollado por la Apache Software Foundation, fue uno de los primeros marcos capaces de escalar horizontalmente el procesamiento de datos distribuidos. Su núcleo está compuesto por *HDFS* (*Hadoop Distributed File System*), que permite almacenar datos de manera segura y redundante en múltiples nodos, y *MapReduce*, el motor que divide las tareas de procesamiento en pequeñas partes que luego se combinan. Este enfoque resultó revolucionario en su momento, ya que permitió que tareas que requerían supercomputadoras pudieran ser ejecutadas en clusters de servidores comunes (Shvachko et al., 2010). Sin embargo, este modelo tiene limitaciones: trabaja con datos almacenados en disco, lo que implica latencias altas, y su flexibilidad es limitada para tareas interactivas o iterativas.

Para responder a estas limitaciones surgió *Apache Spark*, también impulsado por la Apache Foundation, pero diseñado con una lógica diferente. Spark procesa los datos en memoria, lo que permite una velocidad hasta 100 veces mayor que Hadoop en ciertos casos (Karau et al., 2015). Además, ofrece una *API unificada para distintos tipos de procesamiento*: batch, streaming, machine learning y consultas interactivas. Esto permite construir soluciones complejas con un mismo marco de trabajo, facilitando la integración y el mantenimiento del sistema.

Spark también se destaca por su modelo de abstracción basado en *RDD* (*Resilient Distributed Datasets*), que permite trabajar con colecciones de datos distribuidas de forma tolerante a fallos. A diferencia de MapReduce, Spark guarda los datos intermedios en

memoria y solo los escribe en disco cuando es necesario, lo que mejora significativamente el rendimiento en operaciones que requieren múltiples pasos, como los algoritmos de aprendizaje automático (Lantz, 2019).

Otra ventaja importante de Spark es su *compatibilidad con múltiples lenguajes de programación*, como Scala, Java, Python y R. Esto lo hace especialmente atractivo en entornos donde los equipos tienen perfiles diversos. Además, puede integrarse con diversas fuentes de datos (como HDFS, Cassandra, Hive o incluso sistemas relacionales), lo que lo convierte en una herramienta versátil y adaptable a distintos escenarios.

La elección entre Hadoop y Spark no siempre es excluyente. En muchos entornos, *Spark se ejecuta sobre HDFS*, utilizando el sistema de archivos distribuido de Hadoop como base de almacenamiento. Esta combinación permite aprovechar la solidez del almacenamiento de Hadoop junto con la velocidad y flexibilidad de Spark.

En definitiva, tanto Hadoop como Spark representan *dos generaciones de herramientas para el procesamiento distribuido*. Conocer sus características, fortalezas y limitaciones es esencial para poder elegir la solución más adecuada en función del tipo de datos, los tiempos de respuesta requeridos y la infraestructura disponible.

Actividad 4

Te proponemos una actividad que te permitirá *comparar críticamente dos de las herramientas más importantes del procesamiento distribuido de datos*: Hadoop y Apache Spark. A través de esta reflexión, vas a consolidar los conocimientos adquiridos y ejercitar tu capacidad para fundamentar decisiones tecnológicas.

PRÁCTICA PROFESIONALIZANTE II

2º 2º Cuatrimestre



Imaginá que una empresa de logística desea implementar una solución que le permita procesar los datos generados por sus unidades móviles (camiones, motos, sensores de carga, etc.). Los datos incluyen rutas, tiempos de entrega, condiciones del tráfico y eventos inesperados (como accidentes o desvíos), y se generan en forma continua.

El equipo de trabajo duda entre implementar un sistema sobre Hadoop o sobre Apache Spark, y te piden que elabores un informe breve con una recomendación justificada.

En un texto de entre 200 y 300 palabras, explicá:

- *¿Qué herramienta recomendarías en este caso y por qué?*
- *¿Qué aspectos del flujo de datos o de los requerimientos del sistema te llevaron a tomar esa decisión?*
- *¿Qué limitaciones podrías prever con la herramienta no seleccionada?*

Podés apoyarte en los argumentos presentados por *Karau et al. (2015)*, *Shvachko et al. (2010)* y *Lantz (2019)*, pero también es importante que desarrolles una *mirada propia*, considerando los elementos técnicos, funcionales y prácticos del caso.

Esta actividad te ayudará a cerrar la clase con una aplicación concreta del contenido aprendido, y a prepararte para tomar decisiones informadas en situaciones reales donde el análisis de datos debe responder a necesidades dinámicas y en tiempo real.

Instancia de Autoevaluación

PRÁCTICA PROFESIONALIZANTE II

2° 2° Cuatrimestre



Participación en Foro

En esta instancia de autoevaluación deberás participar en el foro de la siguiente manera:

- Recordá leer la colaboración de tus compañeros y evitar repetir respuestas ya elaboradas.
- intervení en las respuestas de otros/as estudiantes aportando argumentos, dudas o preguntas.

Consigna:

A lo largo de esta clase, recorrimos el universo del Big Data, analizamos las diferencias entre el procesamiento batch y en tiempo real, comprendimos la lógica de las arquitecturas distribuidas, y conocimos las principales características de Hadoop y Apache Spark.

Ahora te invitamos a reflexionar:

¿Qué aspectos creés que son más desafiantes a la hora de implementar una arquitectura distribuida para procesamiento de datos? ¿Cuál es, en tu opinión, el criterio más importante para decidir si un sistema debe procesar datos por lotes o en tiempo real?

Tu intervención debe tener entre 120 y 150 palabras. Podés basarte en las lecturas propuestas, los ejemplos trabajados en clase o tu experiencia personal. También podés comentar algún caso que hayas investigado por fuera del aula o vinculado a tu entorno profesional o educativo.

¡Esperamos tu aporte!

Actividad Integradora de Cierre:

PRÁCTICA PROFESIONALIZANTE II

2º 2º Cuatrimestre



En esta actividad integradora de cierre vamos a poner en juego todos los conocimientos que hemos recorrido juntos en esta clase. Tendremos en cuenta los tipos de ejercicios que realizamos, la teoría que leímos y los ejemplos que vimos en los diferentes recursos.

Tu desafío será diseñar una *solución técnica de alto nivel* para un caso simulado, aplicando los conceptos clave del procesamiento distribuido, las arquitecturas batch y real-time, y el uso de herramientas como Hadoop y Spark.

Escenario:

Una organización sin fines de lucro trabaja en la gestión de alertas tempranas para eventos climáticos extremos (inundaciones, olas de calor, tormentas eléctricas). Reciben datos meteorológicos desde sensores instalados en distintas regiones del país, imágenes satelitales en alta resolución, y reportes en tiempo real enviados desde aplicaciones móviles.

La solución tecnológica debe:

- Detectar anomalías de forma inmediata y emitir alertas automáticas.
- Generar reportes mensuales de comportamiento climático.
- Almacenar los datos para análisis posteriores.

Actividad:

Redactá un informe breve (de 300 a 400 palabras) que incluya:

1. ¿Qué tipo de procesamiento utilizarías para cada necesidad del sistema (batch / real-time)?

2. ¿Qué herramientas distribuirías en la arquitectura general (por ejemplo, Spark, Hadoop, Kafka)?
3. ¿Cómo garantizarías escalabilidad, disponibilidad y consistencia en el sistema?

Podés incluir un diagrama conceptual simple para acompañar tu propuesta (opcional). Lo importante es que puedas *articular los conocimientos adquiridos en esta clase y justificar tus decisiones* de diseño con argumentos sólidos, basándote en la bibliografía trabajada, como Karau et al. (2015), Kreps (2011) o Shvachko et al. (2010).

Esta actividad tiene como objetivo que consolides tu comprensión del tema desde una perspectiva práctica y aplicada, tal como lo harás en entornos laborales reales.

3. Cierre/Reflexión Final:

A lo largo de esta clase, hemos recorrido un conjunto de conceptos y herramientas fundamentales para comprender cómo se procesan datos en contextos reales, dinámicos y a gran escala. Analizamos qué es el Big Data, las diferencias entre procesamiento batch y en tiempo real, las características principales de las arquitecturas distribuidas, y el rol que ocupan tecnologías como *Hadoop* y *Apache Spark* en este ecosistema.

Reflexionemos sobre lo que hemos aprendido: ¿por qué es importante tener este conocimiento? Porque en un mundo donde los datos crecen exponencialmente, poder contar con sistemas que respondan de manera eficiente, segura y oportuna es una competencia clave para cualquier profesional del campo de la Ciencia de Datos e

PRÁCTICA PROFESIONALIZANTE II

2º 2º Cuatrimestre



Inteligencia Artificial. Comprender estas arquitecturas nos permite pensar soluciones escalables, sostenibles y adaptadas a los desafíos de cada proyecto.

Te invitamos a que nos dejes tus impresiones sobre lo que aprendimos hoy en los espacios colaborativos habilitados: puede ser una intervención en el foro, una publicación en Padlet, o incluso compartir un enlace a un artículo o video que te haya resultado interesante mientras estudiabas este tema.

Te esperamos en los próximos encuentros. Recordá que es muy importante participar en los foros, asistir a los encuentros sincrónicos y mantenerte activo/a en el desarrollo de cada clase.

El tema del próximo encuentro será:

"Modelos de procesamiento en flujos de datos: Apache Kafka y Apache Storm"

Para ir preparándote, te recomendamos revisar los sitios oficiales de estas herramientas y reflexionar sobre cómo se relacionan con lo que ya venimos aprendiendo.

PRÁCTICA PROFESIONALIZANTE II

2° 2° Cuatrimestre



4. Bibliografía Obligatoria:

- Apuntes académicos de los bloques Programación I, Programación II y Procesamiento de Datos.
- Downey, A. (2015). Think Python: How to Think Like a Computer Scientist (2nd ed.). Green Tea Press.
- Hunt, J. (2019). Beginning Scala 3. Apress.
- Lutz, M. (2013). Learning Python (5th ed.). O'Reilly Media.
- VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly Media.
- Wickham, H. & Golemund, G. (2017). R for Data Science. O'Reilly Media.
- Chisnall, D. (2012). The Definitive Guide to the Java Platform. Addison-Wesley.